CONTEXTO

Las últimas oleadas de incendios en California han llevado a una de las mayores compañías eléctricas de USA a la bancarrota, debido a haber sido sentenciada como culpable por negligencias en el mantenimiento de sus líneas, lo cual se demostró ser la causa de los incendios más importantes (https://edition.cnn.com/2019/01/29/business/pgebankruptcy-fires/index.html).

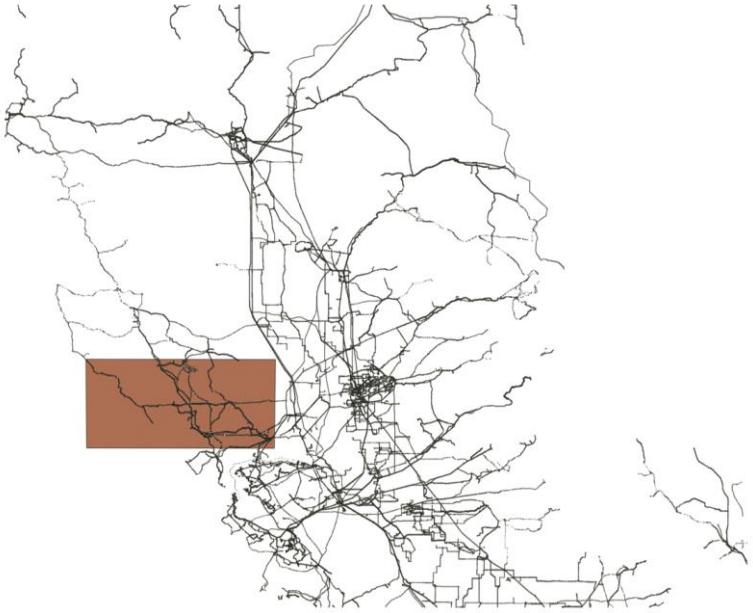

Debido a esto, el gobierno del estado licitó el servicio de suministro eléctrico en todos sus condados. En el caso de los condados de Sonoma y Napa, este servicio cae en manos de la empresa ElectrIAA, especializada en la aplicación de Inteligencia Artificial Avanzada para la optimización de todos sus procesos.

El panorama que se encuentra esta joven, aunque ambiciosa, empresa al inspeccionar el estado de las anteriores instalaciones es desolador, dado que todas las subestaciones generadoras de la línea principal de suministro necesitan ser reemplazadas por motivos de seguridad. Tan solo se trata de 20 estaciones, pero son las encargadas de dar suministro a 1000 urbanizaciones, repartidas por todo el mapa de estos condados. A modo ilustrativo, la figura de arriba muestra la red eléctrica de alta potencia en la mitad norte de California. El rectángulo indica el área del contexto.

Para reemplazar las subestaciones, no hace falta que éstas tengan exactamente la misma ubicación que las anteriores, sino que pueden estar ubicadas en diferentes localizaciones a lo largo del tendido eléctrico que se ve en la figura. El fichero adjunto *transmissionLines_SonomaNapa_1000.txt* es una representación *raster* simplificada del mapa de posibles ubicaciones. Se trata de una grilla de 1000x1000 celdas, donde los valores 1 indican los lugares que reúnen las condiciones para poder instalar una nueva subestación.

Dada esta circunstancia, ElectrIAA decide echar mano de su experiencia en algoritmos evolutivos para optimizar la ubicación de las nuevas subestaciones, tratando de minimizar la distancia promedio entre las nuevas subestaciones y las 1000 urbanizaciones que han de abastecer. Así pues, como expertos que sois, se os encarga diseñar e implementar unos algoritmos genéticos que cumplan de manera óptima con los requisitos del problema.

Como resultado de otros proyectos similares, contáis con unos códigos Python en los ficheros *P3.py* y *utils.py*, que se ajustan bastante a lo que necesitáis hacer, aunque están inacabados.

Actividad 1

Después de analizar brevemente los códigos y entender bien en qué consisten las variables rand_urbanization_map y stations_locations, así como las porciones de código destinadas a configurar el algoritmo genético y funciones de soporte, se pide:

a) Explicar en qué consiste un individuo en el marco de este problema, cómo está representado, y rellenar los huecos existentes en las llamadas a las funciones de configuración. Para la fase de selección, se realizarán torneos entre individuos, cogidos de 3 en 3.

Revisar bien qué se hace con el argumento *individual* en las funciones de *utils.py* para llegar a vuestras conclusiones, y tener en cuenta que los individuos se generan mediante la función deap.tools.initIterate (consultad la documentación de la librería).

b) Configurar el algoritmo genético con las diferentes combinaciones de los siguientes valores para las variables N_POP,N_GEN, cx_prob y mut_prob:

N_POP: 10, 25, 50

N_GEN: 10, 30

cx_prob: 0.2, 0.5

mut_prob: 0.2, 0.55

Mostrar las gráficas generadas que consideréis más relevantes para su discusión en el apartado siguiente.

c) Discutir el efecto de cada una de las variables (o la combinación entre ellas), según lo observado tras las ejecuciones del apartado anterior.

Actividad 2

Después de comprobar que, efectivamente, se puede optimizar la ubicación de nuestras subestaciones según el criterio de minimizar la distancia promedio, queremos ir un paso más allá y, en vez de definir un único objetivo, queremos optimizar nuestros resultados en base a un objetivo múltiple. En este caso se establecen 2 criterios extra:

Que, por cuestiones de eficiencia en el mantenimiento de toda la red, además de minimizar el promedio de todas las distancias, se minimice también la desviación estándar.

Que, por una cuestión logística, se minimice también la distancia promedio de todas las subestaciones a la estación principal de la compañía, que estará ubicada en la posición (0,0) del mapa (fuera de las ubicaciones posibles para el resto de subestaciones).

a) Completar las funciones stdev_distance y avg_distance_to_main en el fichero *utils.py* (fijáos en qué y cómo lo hace la función avg_distance que se os da ya implementada).

Modificar también la función fitness para que devuelva los valores correspondientes a los 3 criterios (el inicial más los 2 nuevos).

b) Modificar las instrucciones necesarias para que el algoritmo genético ahora trabaje con individuos con una función multiobjetivo.

Otorgar un peso de -1, -0.8 y -0.5 a los 3 diferentes criterios (avg_distance, stdev_distance y avg_distance_to_main, respectivamente), y comprobad que el algoritmo genético multiobjetivo funciona correctamente. ¿Por qué estos valores son negativos?

Actividad 3

a) En el código base (fichero *P3.py*) encontramos estas dos líneas:

```
seq = [i for i in range (0,999999)]
rand_urbanization_map = sample(seq,1000)
```

¿Qué implicaciones tienen, a la hora de evaluar los resultados de diferentes ejecuciones? ¿Sería útil contar siempre con una misma distribución de urbanizaciones en el mapa?

b) Si ejecutamos el código varias veces fijando una misma configuración de las del apartado 1b), enseguida vemos que no hay una varianza destacable entre ejecuciones, en cuanto a la velocidad de convergencia del algoritmo y valores alcanzados. Razonar qué nos indica este hecho.
c) Imaginar que, en vez de la codificación escogida para representar a los individuos, se escogiese una codificación binaria, consistente solo en valores 0 y 1. ¿Qué ventajas e inconvenientes tendría esto?
d) Como se puede observar, en nuestro caso la función registrada 'individual' utiliza la función toolbox.initIterate de DEAP. ¿Qué diferencia hay entre ésta y la función toolbox.initRepeat que podemos ver en otros muchos ejemplos? ¿Por qué initRepeat no sería adecuada en nuestro caso?
e) En el código base (fichero P3.py) encontramos estas dos líneas de código de decoración, aplicado a las operaciones de cruzamiento y mutación:

```
# GA decoration
toolbox.decorate('mate', fulfill_constraints())
toolbox.decorate('mutate', fulfill_constraints())
```

¿Por qué no es necesario aplicar la decoración en la operación 'population', encargada de generar la población de individuos? Consultar el manual de DEAP para entender el procedimiento de decoración.

Actividad 4

En el código proporcionado, la función de decoración fulfill_constraints tan solo consiste en un esqueleto que, al fin y al cabo, no hace nada. En este ejercicio vamos a completarla para que, efectivamente, decore a los individuos que se generan a partir de las operaciones de cruzamiento y mutación.
a) Antes de ponernos a decorar, obviamente, nos tenemos que preguntar por qué es necesario hacerlo. Razonar a continuación qué aspectos de nuestros individuos hacen necesaria la decoración para asegurarnos de que el algoritmo genético funciona correctamente y nos dará resultados útiles.
b) Completar el código de la función fulfill_constraints, de acuerdo a nuestra respuesta del apartado anterior.